

03 MLP

本节内容


1. 课程引入与问题背景
2. 电路启发：组合解决异或
3. 多层感知机原理与结构
4. 非线性激活的必要性
5. 训练难题与反向传播

电路启发

逻辑电路异或门

💡 提示 由简单模块组合复杂功能

XOR 问题早在逻辑电路得到解决，计算机的异或门是由更基础的门电路组合而成的



- $\text{OR} \rightarrow x_1 \vee x_2$: 至少一个输入为 1

- $\text{NAND not and} \rightarrow \text{NOT}(x_1 \text{ AND } x_2)$: 两个输入不同时为 1


对第二步中的两个逻辑结果取且 (AND),
仅当一个输入为 1 并且另一输入为 0 时,
最终输出会为 1, 这就是异或的定义

多线包围复杂区域

将上述组合堆叠的思路代入感知机应用


单个感知机在特征空间里仅构造单条直线, 或在高维空间的超平面, 只能线性分割

如果增加感知机的数量, 那么可以包围任意复杂的区域



两层感知机解决XOR

💡 **提示** 两层感知机通过组合简单的线性分隔 (OR 和 NAND), 在最后一层实现异或 (XOR)



- 输入层
接收两个特征 x_1, x_2
- 隐藏层
两个神经元使用不同的权重并行运算，各自画一条分割线，输出 0 或 1
- 输出层
将隐藏层的两个输出作为输入，再一次加权求和后激活，得到异或判断

第一个隐藏层学会 **至少一个输出为 1**

第二个隐藏层学会 **输出不能同时为 1**


输出层对两个条件取交集

多层感知机的原理与结构

多层结构的思想来源

神经科学

1940 年，神经科学家发现大脑皮层是分层处理的



视觉信号从视网膜出发，经过 V1, V2, V4, IT 等多个区域逐级加工


底层神经元响应边缘和方向，高层神经元响应人脸和物体

1943 年的 M-P 神经元模型的设计目标就是通过数学描述大脑的工作方式

函数逼近理论

任何函数都可以用简单函数的组合来逼近

- 泰勒展开通过多项式实现逼近 - 傅里叶变换通过正弦波的叠加实现逼近




代入神经网络:

一个神经元是简单的函数单元，多个神经元的组合可以逼近更复杂的函数，多层组合可以逼近任意复杂的函数

多层感知机的一般结构

将多个感知机按层排列，在层间全连接，构成 **多层感知机 (MLP)** 即为最基础的神经网络



- 输入层接收原始特征，数个隐藏层进行中间预算，输出层给出最终结果
- 同一层的神经元 **并行提取多个不同的特征或规则**
- 后续层将前一层的输出作为输入，利用不同权重进一步组合，**逐层构造更加抽象、更加有效的表达**

数学表达：函数的层层嵌套

$$\text{output} = h_n(h_{n-1}(\cdots (h_2(h_1(X))))))$$

非线性激活的必要性

为何多层线性变换无效

假设

第一层输出为 $h = W_1x + b_1$

第二层输出为 $y = W_2h + b_2$

即 $y = W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$

令 $W' = W_2W_1$, $b' = W_2b_1 + b_2$

则 $y = W'x + b'$, 仍为线性形式

💡 **提示** 线性变换的组合仍是线性变换

即便层层叠加也是徒劳


使用激活函数打破线性

在每个神经元的加权求和输出上加一个非线性函数，称为 **激活函数 (Activation Function)**

$$h = f(Wx + b)$$

引入非线性的 f ，层间组合无法被化简为单一线性变换

阶跃函数 (Step Function)



$$\text{step}(z) = \begin{cases} 1 & \text{若 } z \geq 0 \\ 0 & \text{若 } z < 0 \end{cases}$$

万能逼近定理

1989 年正式证明了 **万能逼近定理 (Universal Approximation Theorem)**

一个含有充足神经元的单隐藏层 MLP, 可以任意精度逼近任意连续函数

- 意味 MLP 在理论上具备表达任何函数的能力

- **表达能力** (足够多神经元) 和 **训练能力** (如何找到正确权重) 是两个不同问题

深度学习而非宽度学习

后续训练发现增加隐藏层的层数，比增加层内的神经元数量，能取得更佳的效果

训练难题与反向传播

模型训练仍是难题

多层网络能力如此强大，为何深度学习还会经历二十多年寒冬？

- MLP 结构早在 1960 年代提出，虽然有人想到多层网络，但是 **没法训练**
- 当时的感知机学习规则 **只适用于单层网络**
- **核心难题是如何分配隐藏层误差**

1. 如何分配层间误差，确定哪个隐藏层的误差 2. 如何分配层内误差，确定哪个神经元权重的误差

1986 年，**反向传播算法 (Back propagation)** 与多层网络结合，形成高效计算多层梯度方法